

Расчет сложения

Формат входа: $B \times 3 \times 3 \times S$, где B - размер батча, S - размер 16

$$\text{План } x = BS^2$$

Для свертки и max pool при dilation = 1: $H_{out} = \left(\frac{H_{in} + 2p - k}{S} \right) + 1$, где k - размер ядра, p - padding

Для max значения k, s, p и формула выхода:

$$\text{Conv1} - 7, 2, 3 - 32 \times (S/2) \times (S/2)$$

$$\text{MaxPool} - 3, 2, 1 - 32 \times (S/4) \times (S/4)$$

$$\text{Conv2} - 5, 1, 2 - 64 \times (S/4) \times (S/4)$$

$$\text{Conv3} - 3, 2, 1 - 128 \times (S/8) \times (S/8)$$

$$\text{Conv4} - 1, 1, 0 - 256 \times (S/8) \times (S/8)$$

$$\text{Conv5} - 3, 2, 1 - 256 \times (S/16) \times (S/16)$$

$$\text{Conv6} - 1, 1, 0 - 512 \times (S/16) \times (S/16)$$

$$\text{Global AvgPool} - 512 \times 1 \times 1$$

$$\text{Flatten} - 512$$

$$\text{linear1} - 256$$

$$\text{linear2} - 100$$

Для Conv число параметров $P_i = C_{out} C_{in} K^2$, число вычислений $N_i = B C_{out} H_{out}^2$, число операций $F_i = 2 N_i C_{in} K^2$.

Для linear с входом m и выходом n : $P_i = mn + n$, $F_i = B(2mn + n)$

Для Conv1: $P_1 = 32 \cdot 3 \cdot 7^2 = 4704$; $N_1 = 32 B (S/2)^2 = 8x$; $F_1 = 2 \cdot 8x \cdot 3 \cdot 7^2 = 2352x$

Для всех слоев:

Слой

Conv1 | P_i | Flops, F_i

$$\text{Conv1} \quad 4704 \quad 2352x$$

$$\text{Conv2} \quad 64 \cdot 32 \cdot 25 = 51200 \quad 6400x$$

$$\text{Conv3} \quad 128 \cdot 64 \cdot 9 = 73728 \quad 2304x$$

$$\text{Conv4} \quad 256 \cdot 128 = 32768 \quad 1024x$$

$$\text{Conv5} \quad 256 \cdot 256 \cdot 9 = 589824 \quad 4608x$$

$$\text{Conv6} \quad 512 \cdot 256 = 131072 \quad 1024x$$

$$\text{linear1} \quad 512 \cdot 256 + 256 = 131328 \quad 262400x$$

$$\text{linear2} \quad 256 \cdot 100 + 100 = 25700 \quad 51300B$$

$$\text{Умнож: } P = \sum P_i = 1040324$$

$$F = (2352 + 6400 + 2304 + 1024 + 4608 + 1024 + 2)X + (262400 + 51300)B$$

$$\text{Flops}(S, B) = 17714 BS^2 + 313700B$$

Память:

$$A = (3 + 8 + 2 + 4 + 2 + 4 + 1 + 2)X + (1512 + 256 + 100)B = 26X + 868B$$

$$\text{Memory}(S, B) = 4(P + A) = 4(1040324 + 26BS^2 + 868B) \text{ байт}$$

Передача данных:

$$D_i = 4(N_{in,i} + P_i + N_{out,i}) \quad P_{ch} = 8N \quad D_{flatten} = 0$$

Суммируя все:

$$D/4 = P + (11 + 6 + 6 + 6 + 5 + 3)X + 10X + (2X + 512B) + (16 + 8 + 4 + 8 + 2 + 4)X + 512B + (768 + 356)B$$

$$D(S, B) = 4(1040324 + 91BS^2 + 2148B) \text{ байт}$$

Задержка:

$$t_i = \max\left(\tau, \frac{F_i(S, B)}{C}, \frac{P_i(S, B)}{W}\right), \text{ где 17 операций:}$$

$$\text{Latency}(S, B, \theta) = T = \sum_{i=1}^{17} t_i$$

Энергия

$$\text{Для всего графа } E = \int_0^T p(t) dt$$

$$\text{Пусть } U = T - 17\tau \geq 0$$

$$\text{Energy}(S, B, \theta) = p_0 T + p_1 (T - 17\tau)$$

$$\theta_E = (\tau, C, W, p_0, p_1) \quad p_0, p_1 \geq 0$$